URBANE LUFTVERSCHMUTZUNG · FEATURE ENGINEERING

Feinstaub schätzen, wo keine Messstation steht

Welche Satelliten- und Wetterdaten ein PM2.5-Modell wirklich braucht

Vorlage für Umweltministerien

Stand: November 2026

AUSGANGSLAGE

Die Datengrundlage: Satelliten- und Wetterdaten

340

Orte mit PM2.5-Messung (Feinstaubbelastung in µg/m³)

30.557

Tageswerte (01.2020-04.2020)

74

Schadstoffmessdaten aus Satellit und Wetter

0

gemeinsame Orte mit den 179 Prüf-Orten

Das Modell muss auf Orte übertragbar sein, die es nie gesehen hat.

VORGEHEN

Das Vorgehen in drei Schritten

1

Merkmale bauen

Aus 74 Messdaten werden 177 Merkmale in neun Gruppen.

→

2

Gruppen prüfen

Jede Gruppe wird an Orten getestet, die das Modell nicht kennt.

→

3

Auswählen

Übrig bleibt das kleinste gleich gute Set: 20 Merkmale.

Gegen geschönte Ergebnisse: keine Ortskennung, keine Information aus den Messwerten.

VORGEHEN

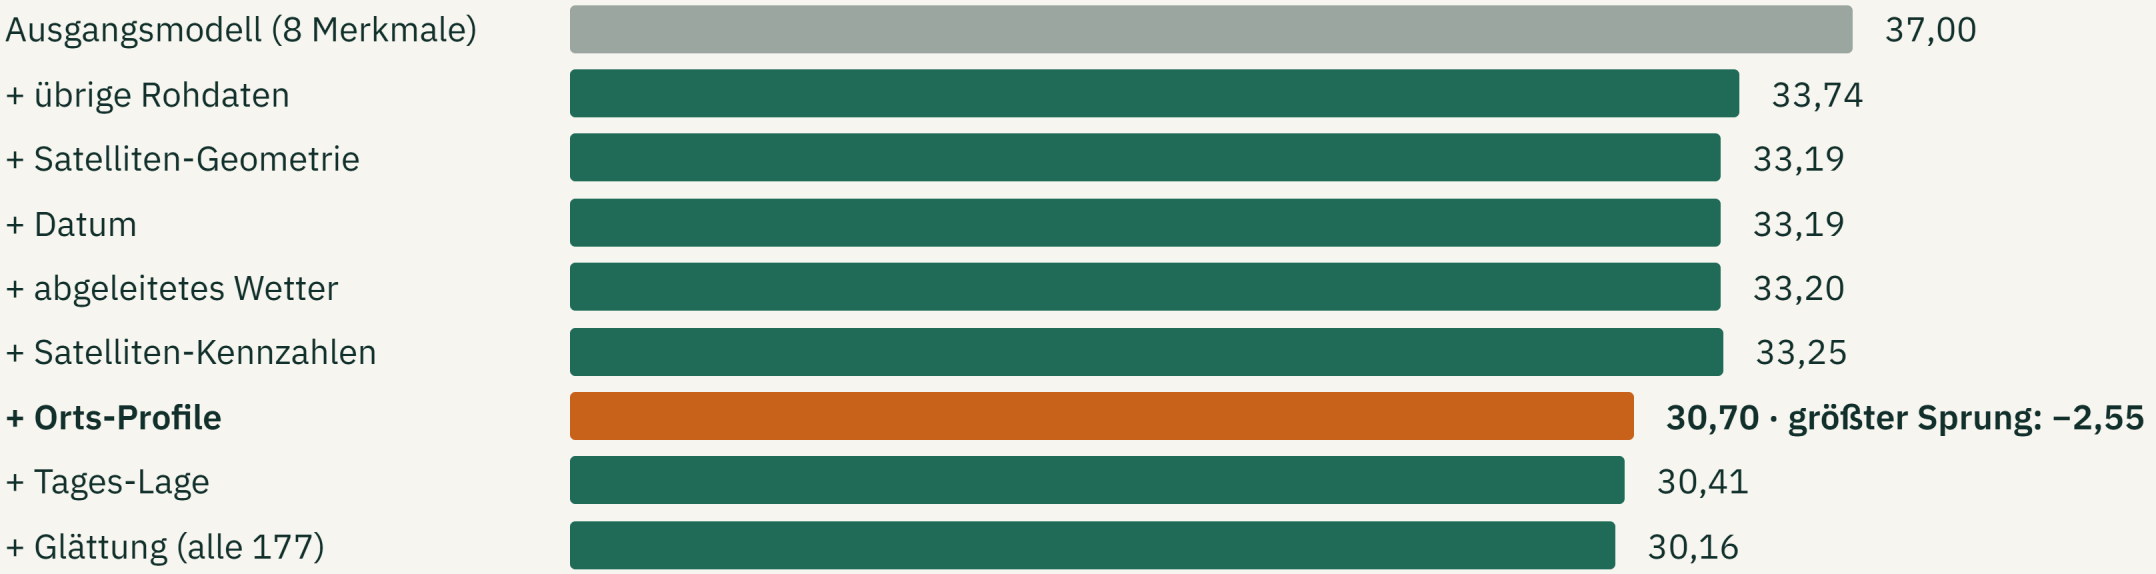
Die neun Merkmalsgruppen im Überblick

Gruppe	Anzahl	Inhalt	Idee dahinter
Ausgangsmodell	8	Wind, Schadstoffe, Wolken, Datum	Vergleichsmaßstab
Übrige Rohdaten	39	weitere Mess- und Wetterspalten	mehr Signal
Satelliten-Geometrie	35	Blickwinkel, Sonnenstand, Bahnhöhe	Aufnahmebedingungen
Datum	3	Tag im Jahr, Wochentag	Jahreszeit, Verkehr
Abgeleitetes Wetter	5	Wind, Feuchte, Taupunkt	Ausbreitung der Partikel
Satelliten-Kennzahlen	5	Gasverhältnisse, Bewölkung, Lücken	Messqualität
Orts-Profile	42	Mittel und Streuung der Messdaten je Ort	Grundbelastung
Tages-Lage	28	Mittel je Tag über alle Orte	Wetterlage
Glättung	20	Mittel über 3 und 7 Tage	gleicht Lücken aus

ERGEBNISSE

Orts-Profile sind besonders relevant für das Modell

Typischer Fehler (RMSE) an unbekannten Orten. Kürzer ist besser.

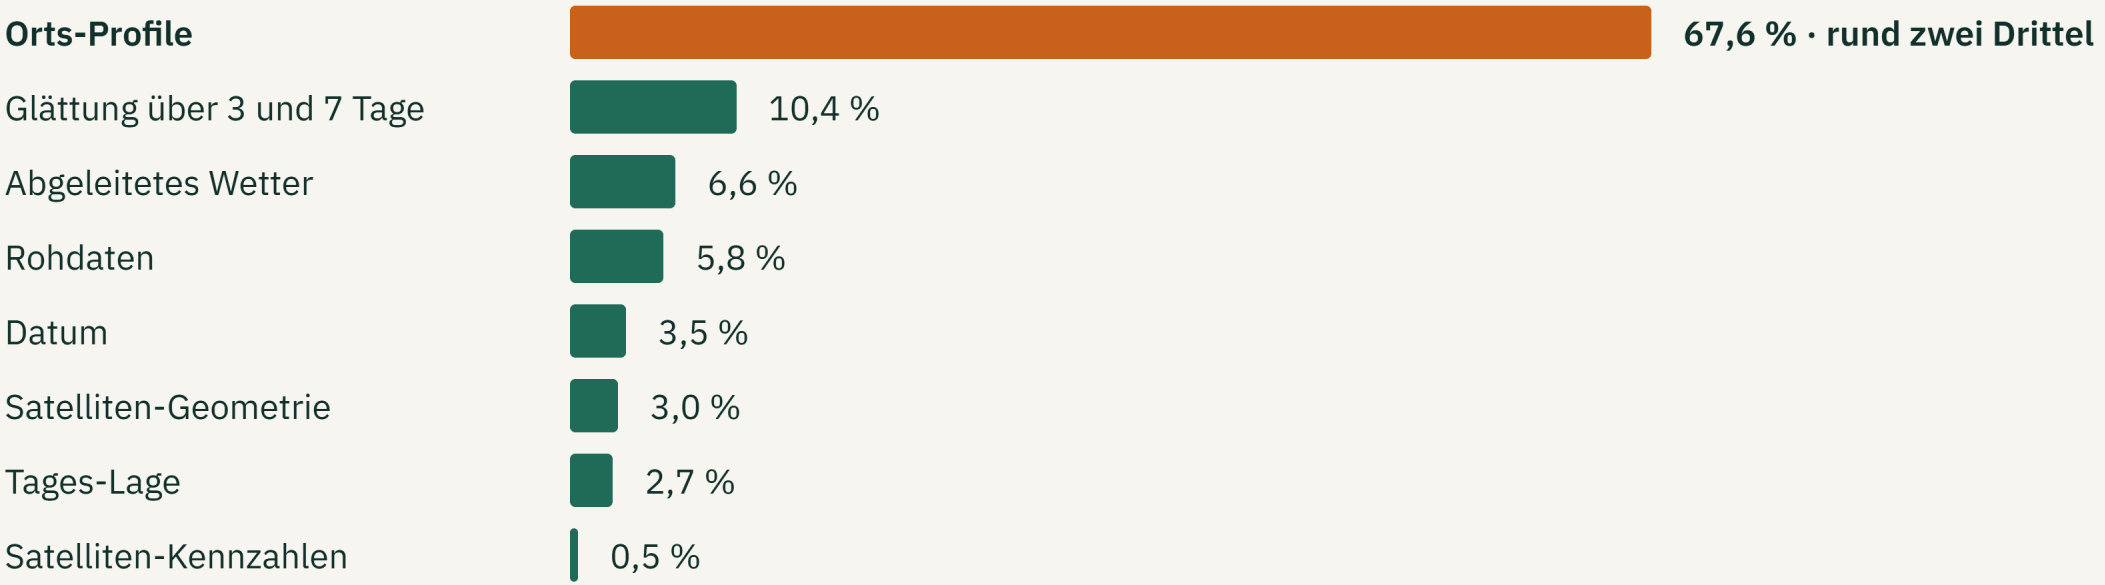


62 % der Unterschiede im Feinstaub liegen zwischen den Orten, nicht zwischen den Tagen.

ERGEBNISSE

Worauf sich das Modell stützt

Anteil jeder Gruppe an der Wichtigkeit im Modell mit allen 177 Merkmalen.



ERGEBNISSE

Die wichtigsten Schadstoffwerte und ihre Entstehung

Schadstoff	Rang	So entsteht er
Formaldehyd (HCHO)	1	Heizen mit Kohle, Verkehr und Industrie; Brände
Kohlenmonoxid (CO)	2	Unvollständige Verbrennung: Verkehr, Heizen, Industrie, Brände
Methan (CH4)	8	Viehhaltung, Reisanbau, Deponien, Förderung von Gas, Öl und Kohle
Ozon (O3)	11	Bodennah aus Stickoxiden bei Sonne; der Satellit misst vor allem die Ozonschicht
Stickstoffdioxid (NO2)	14	Heiße Verbrennung: Verkehr, Kraftwerke, Industrie, Heizungen

20 statt 177 Merkmale bei fast gleichem Fehler (30,4 statt 30,2). Ebenfalls weit vorn: Windstärke (Rang 3), Jahreszeit (Rang 6).

Rang = Bedeutung für die Vorhersage, kein Nachweis einer Ursache

GRENZEN

Die Schwachstelle: Tage mit sehr hoher Belastung

PM2.5-Bereich	Tageswerte	Fehler vorher	Fehler jetzt
bis 25	7.718	25,1	17,9
25 bis 50	7.635	17,9	14,3
50 bis 100	10.265	18,8	17,3
100 bis 150	2.627	41,9	32,1
150 bis 200	2.056	64,7	46,6
über 200	256	131,1	100,9

42 %

des quadratischen Fehlers stammen von nur 8 % der Tageswerte: jenen über 150.

Fehler = mittlere absolute Abweichung (MAE); vorher = Ausgangsmodell, jetzt = 20 Merkmale

EMPFEHLUNGEN

Die Folgerungen für die Umweltverwaltung

Als Screening einsetzen

Zeigt, welche Orte ohne Messstation vermutlich belastet sind. Ersetzt keine Messung.

CO und Formaldehyd beobachten

Dauerhaft hohe Werte markieren Orte für neue Messstationen und eine Prüfung der Quellen.

Zeitreihen je Ort sammeln

Orts-Profile brauchen viele Tage an Daten je Ort.

Keine Alarme darauf stützen

Spitzenwerte werden unterschätzt. Warnungen brauchen weiter Messstationen.

Nächste Schritte: Modell feinjustieren und an den 179 zurückgehaltenen Orten prüfen.

ERGEBNISSE

Die Satelliten-Geometrie: 35 Spalten ohne Mehrwert

Ohne Geometrie · 142 Merkmale

30,19

Fehler an unbekannten Orten

Mit Geometrie · 177 Merkmale

30,16

Unterschied 0,03, also Rauschen

Im finalen Set

0 von 20

Geometrie-Spalten ausgewählt

Blickwinkel und Bahnhöhe wirken wie eine verdeckte Ortskennung. Orts-Profile liefern dieselbe Information direkter.